

数据融合角度推导卡尔曼增益（Kalman Gain, K）的核心思想



王志博

今天修改

从数据融合角度推导卡尔曼增益（Kalman Gain, K）的核心思想是：找到最优权重，将模型预测值 $\hat{x}_k^-$ 和观测值 z_k 融合起来，形成后验估计值 $\hat{x}_k$ ，使得融合后的估计值 $\hat{x}_k$ 尽可能接近真实状态 x_k ，或者说最小化估计误差的方差。

以下是详细的推导步骤：

1. 数据融合的基本模型

后验状态估计值 $\hat{x}_k$ 是预测值 $\hat{x}_k^-$ 和测量值 z_k 的线性组合：

$$\hat{x}_k = \hat{x}_k^- + K_k * (z_k - H * \hat{x}_k^-)$$

- $\hat{x}_k^-$ ：先验状态估计值（基于系统模型预测的状态）
- z_k ：实际观测值（从传感器获得）
- H ：观测矩阵（将状态空间映射到观测空间）
- K_k ：卡尔曼增益矩阵（当前时刻的待求权重矩阵）
- $(z_k - H * \hat{x}_k^-)$ ：测量残差 / 新息（Innovation），表示实际观测值与预测观测值之间的差异。

2. 估计误差

定义后验状态估计误差：

$$e_k = x_k - \hat{x}_k$$

代入数据融合模型：

$$e_k = x_k - [\hat{x}_k^- + K_k * (z_k - H * \hat{x}_k^-)]$$

3. 引入测量模型

实际观测值 z_k 与真实状态 x_k 的关系是：

$$z_k = H * x_k + v_k$$

其中 v_k 是均值为零、协方差为 R ($E[v_k v_k^T] = R$) 的测量噪声。

4. 将 z_k 代入误差表达式：

$$e_k = x_k - [\hat{x}_k^- + K_k * ((H * x_k + v_k) - H * \hat{x}_k^-)]$$

整理：

$$e_k = x_k - \hat{x}_k^- - K_k * H * x_k + K_k * v_k + K_k * H * \hat{x}_k^-$$

$$e_k = (x_k - \hat{x}_k^-) - K_k * H * (x_k - \hat{x}_k^-) - K_k * v_k$$

$$e_k = (I - K_k * H) * (x_k - \hat{x}_k^-) - K_k * v_k$$

5. 定义先验误差

令 $e_k^- = x_k - \hat{x}_k^-$ 为先验估计误差。先验估计误差的协方差矩阵定义为：

$$P_k^- = E[e_k^- (e_k^-)^T]$$

6. 根据卡尔曼滤波公式，预测步骤已计算了 P_k^- ：

$$P_k^- = F * P_{k-1} * F^T + Q$$

（其中 F 是状态转移矩阵， Q 是过程噪声协方差）

7. 求解后验误差协方差矩阵

后验误差协方差矩阵 $P_k = E[e_k e_k^T]$ 是衡量后验估计值 $\hat{x}_k$ 不确定性的关键指标。

代入误差表达式：

$$P_k = E[\{ (I - K_k * H) * e_k^- - K_k * v_k \} * \{ (I - K_k * H) * e_k^- - K_k * v_k \}^T]$$

展开（利用期望的线性性质和独立性假设）：

$$P_k = E[(I - K_k * H) * e_k^- * (e_k^-)^T * (I - K_k * H)^T]$$

$$- E[(I - K_k * H) * e_k^- * (-K_k v_k)^T]$$

$$- E[(-K_k v_k) * (e_k^-)^T * (I - K_k * H)^T]$$

$$+ E[(-K_k v_k) * (-K_k v_k)^T]$$

8. 关键假设：

- 先验估计误差 e_k^- 与测量噪声 v_k 相互独立 ($E[e_k^- * v_k^T] = 0$)
- 测量噪声均值为零 ($E[v_k] = 0$)

9. 根据这两个独立性和零均值假设，中间两项的期望为 0：

$$E[(I - K_k * H) * e_k^- * (-K_k v_k)^T] = (I - K_k * H) * E[e_k^- v_k^T] * (-K_k)^T = 0$$

$$E[(-K_k v_k) * (e_k^-)^T * (I - K_k * H)^T] = (-K_k) * E[v_k (e_k^-)^T] * (I - K_k * H)^T = 0$$

10. 因此，表达式简化为：

$$P_k = (I - K_k * H) * E[e_k^- (e_k^-)^T] * (I - K_k * H)^T + E[K_k v_k * (K_k v_k)^T]$$

$$P_k = (I - K_k * H) * P_k^- * (I - K_k * H)^T + K_k * E[v_k v_k^T] * K_k^T$$

$$P_k = (I - K_k * H) * P_k^- * (I - K_k * H)^T + K_k * R * K_k^T \quad (\text{因为 } R = E[v_k v_k^T])$$

11. 最小化方差（协方差迹）

“最优估计”的目标是最小化 P_k 的迹 $\text{Tr}(P_k)$ 。迹 $\text{Tr}(P_k)$ 等于后验状态估计误差的总方差（各个维度误差方差之和）。最小化这个总方差等价于寻找一个 K_k ，使得融合后的估计值在整体上最接近真实值。

12. 我们需要找到合适的矩阵 K_k 使得标量函数 $\text{Tr}(P_k)$ 最小。标准方法是对 K_k 求偏导，并令其等于零：

$$\partial[\text{Tr}(P_k)] / \partial K_k = 0$$

13. 对迹函数求导（关键步骤）

利用矩阵迹的微分规则和对矩阵变量求导的公式：

$$d(\text{Tr}(P_k)) = d(\text{Tr}[(I - K_k * H) * P_k^- * (I - K_k * H)^T]) + d(\text{Tr}[K_k * R * K_k^T])$$

14. 分别计算：

第一项：

设 $A = (I - K_k * H)$ ， $B = P_k^-$ 。

$$d(\text{Tr}[A * B * A^T])。$$

$$\text{利用 } d(\text{Tr}(A * B * A^T)) = \text{Tr}([dA] * B * A^T + A * B * [dA^T] + A * [dB] * A^T)$$

由于 $dB = dP_k^- = 0$ （ K_k 变化时先验协方差固定）且 $dA = -d(K_k)H$ ，利用 $\text{Tr}(X) = \text{Tr}(X^T)$ ：

$$d(\text{Tr}[A * B * A^T]) = 2\text{Tr}(A * B * [dA^T]) \quad (\text{近似规则})。$$

因此：

$$d(\text{Tr}[(I - K_k * H) * P_k^- * (I - K_k * H)^T]) = 2\text{Tr}([(I - K_k * H) * P_k^- * H^T] * dK_k^T) \quad (\text{推导过程中需特别注意矩阵转置和微分顺序})$$

更常见和严谨的形式是：

$$d(\text{Tr}[(I - K_k * H) * P_k^- * (I - K_k * H)^T]) = 2\text{Tr}((I - K_k * H) * P_k^- * (-H)^T * dK_k) + 2\text{Tr}((I - K_k * H) * P_k^- * (-H * dK_k)^T) \quad (\text{这步是难点})$$

经过仔细推导（利用迹的线性性质、迹的转置不变性、微分链式法则等），最终得到：

$$d(\text{Tr}[(I - K_k * H) * P_k^- * (I - K_k * H)^T]) = \text{Tr}([2 * (K_k * H * P_k^- * H^T - P_k^- * H^T)] dK_k) \quad (\text{需要匹配 } dK_k \text{ 的系数})$$

15. 第二项：

$$d(\text{Tr}[K_k * R * K_k^T])$$

设 $C = K_k$ ， $D = R$ 。

$$d(\text{Tr}[C * D * C^T]) = 2\text{Tr}((C * D)^T * dC) = 2\text{Tr}(D * C^T * dC)$$

更严谨：

$$d(\text{Tr}[K_k * R * K_k^T]) = \text{Tr}(d(K_k * R * K_k^T)) = \text{Tr}([dK_k] * R * K_k^T + K_k * R * [d(K_k^T)])$$

利用 $\text{Tr}(M) = \text{Tr}(M^T)$ 和 $d(K_k^T) = (dK_k)^T$ ：

$$= \text{Tr}([dK_k] * R * K_k^T) + \text{Tr}((K_k * R * [dK_k]^T)^T) \quad (\text{后一项转置}) = \text{Tr}([dK_k] * R * K_k^T) + \text{Tr}((K_k * R) * dK_k) \quad (\text{利用 } \text{Tr}(X^T) = \text{Tr}(X))$$

$$= \text{Tr}((R * K_k^T + K_k^T * R) dK_k) \quad ? \quad (\text{或等效形式： } 2\text{Tr}(K_k * R * dK_k^T) \quad ?)$$

最终常见形式：

$$d(\text{Tr}[K_k * R * K_k^T]) = \text{Tr}([2 * K_k * R] dK_k)$$

16. 合并：

$$d(\text{Tr}(P_k)) = d(\text{Tr}(\text{第一项})) + d(\text{Tr}(\text{第二项})) = \text{Tr}([2(K_k H P_k^{-1} H^T - P_k^{-1} H^T) + 2K_k R] dK_k)$$

17. 令偏导为零并求解 K_k

要求 $d(\text{Tr}(P_k)) = 0$ 对所有微元 dK_k 成立，等价于要求 $d(\text{Tr}(P_k))$ 中 dK_k 的系数矩阵为零：

$$2(K_k H P_k^{-1} H^T - P_k^{-1} H^T) + 2K_k R = 0$$

两边除以2：

$$K_k H P_k^{-1} H^T - P_k^{-1} H^T + K_k R = 0$$

合并含 K_k 的项：

$$K_k (H P_k^{-1} H^T + R) = P_k^{-1} H^T$$

如果 $(H P_k^{-1} H^T + R)$ 可逆（通常成立），则解得 K_k ：

$$K_k = P_k^{-1} H^T * (H P_k^{-1} H^T + R)^{-1}$$

结论与解读

1. 卡尔曼增益公式：

$$K_k = P_k^{-1} H^T (H P_k^{-1} H^T + R)^{-1}$$

这个公式完全从最小化融合后状态估计的总方差的角度推导出来。它告诉我们应该如何给“模型预测值” $\hat{x}_k$ 和“传感器测量值” z_k 分配最优权重，使得结合两者的估计值 $\hat{x}_k$ 最接近真实状态 x_k （在均方误差最小意义上）。

2. 数据融合的视角：

- $H P_k^{-1} H^T$ ：表示预测值 $\hat{x}_k$ 在观测空间中的不确定性（协方差）。 P_k^{-1} 是状态空间的先验估计协方差， H 将其投影到观测空间。
- R ：表示测量值 z_k 本身的不确定性（噪声协方差）。
- $(H P_k^{-1} H^T + R)$ ：观测空间的总不确定性。它结合了模型预测的不确定性和传感器测量的不确定性。这个矩阵的逆本质上是总不确定性的度量取逆。

- $P_k^- H^T$: 表示状态空间预测误差与观测空间预测误差之间的协方差。 H^T 将 $H P_k^- H^T$ 的信息（在观测空间）映射回状态空间。

3. K_k 的直观意义：卡尔曼增益 K_k 将观测空间的总不确定性 ($(H P_k^- H^T + R)^{-1}$) 与状态预测和观测预测之间的相关性 ($P_k^- H^T$) 相结合。它体现了：

- 对预测的信任程度：如果预测非常准确 (P_k^- 很小 $\rightarrow H P_k^- H^T$ 很小)，那么 $(H P_k^- H^T + R)$ 主要由 R 决定。如果测量噪声也小 (R 小)，那么 $(H P_k^- H^T + R)^{-1}$ 会很大，同时 $P_k^- H^T$ 相对于 R 也较大，综合结果 K_k 会较大。大的 K_k 意味着 $\hat{x}_k$ 会更倾向于相信测量值（因为测量也很准）。
- 对测量的信任程度：如果测量非常准确 (R 很小)，那么 $(H P_k^- H^T + R)^{-1}$ 会很大（因为整体不确定性非常小），同时 $P_k^- H^T$ 的大小相对不那么重要（除非 P_k^- 也特别大），结果 K_k 也会较大。大的 K_k 同样意味着更相信测量值。
- 不确定性最小化的权衡：无论预测准还是测量准， K_k 的值都是为了让融合后的 P_k （后验协方差）最小化。公式 $K_k = P_k^- H^T (H P_k^- H^T + R)^{-1}$ 是实现状态空间估计总方差 $\text{Tr}(P_k)$ 最小化的最优权重系数。它的作用就是动态地、根据模型和测量的实时不确定性 (P_k^- , R)，最优地混合预测值和观测值。